

AI SCIENCE LAB

AI for Science: 蛋白设计基础模型与 workflows

From Protein Models to Designed Molecules

AI Science Lab

2026-06-04

目录 / Contents

AI for Science：蛋白设计基础模型与 workflows

2026 技术调研简报

执行摘要

技术背景

1.1 蛋白质设计的核心挑战

1.2 AI 的革命性突破

1.3 市场与应用背景

主流基础模型与工具全景

2.1 结构预测类模型

2.2 生成式骨架设计模型

2.3 序列设计模型

2.4 蛋白质语言模型 (PLM)

2.5 功能预测工具

序列 - 结构 - 功能标准 workflows

3.1 阶段一：骨架生成

3.2 阶段二：序列设计

3.3 阶段三：结构验证（自治过滤）

3.4 阶段四：功能注释与适应性预测

模型对比表

实施建议

4.1 项目启动阶段：选型建议

4.2 计算基础设施建议

4.3 工作流集成建议

风险与局限性

5.1 模型幻觉与过度自信

5.2 复杂靶点能力不足

5.3 训练数据偏差

5.4 开源与商业授权问题

5.5 计算成本

5.6 实验验证仍是决定性环节

总结与展望

参考文献

AI for Science：蛋白设计基础模型与 workflows

2026 技术调研简报

报告分类：公开技术调研 | 发布时间：2026 年 | 领域：计算生物学 · AI for Science

执行摘要

人工智能驱动的蛋白质设计正经历一场范式革命。从 AlphaFold2 奠定结构预测的精度基准，到以 RFdiffusion、ESM3、AlphaFold3 为代表的生成式基础模型相继涌现，蛋白质工程正从“经验试错”转向“计算优先、实验验证”的全新模式。

本简报面向计算生物学、药物研发及生物技术领域的技术决策者，系统梳理截至 2026 年上半年的主流 AI 蛋白设计基础模型、标准化 workflows 及工程实践要点，并给出模型选型建议与关键风险提示。

核心发现：

- **结构预测**已基本成熟：AlphaFold3、Chai-1、Boltz-1 在蛋白质 - 配体、蛋白质 - 核酸、抗体 - 抗原等复合体预测上达到或超越传统实验精度。
- **生成式设计**快速成熟：RFdiffusion / RFdiffusion2 + ProteinMPNN / LigandMPNN 已成为主流从头设计流水线；ESM3 实现了序列 - 结构 - 功能的统一多模态推理。
- **标准 workflows**已形成：骨架生成 → 序列设计 → 结构验证 → 功能筛选的四阶段流水线被广泛采用，成功率较传统方法提升 10-100 倍。
- **实验验证仍是瓶颈**：计算成功率与湿实验成功率之间仍存在显著差距，复杂靶点（GPCR、离子通道）的设计能力仍受限于结构数据稀缺。

技术背景

1.1 蛋白质设计的核心挑战

蛋白质由氨基酸序列（一级结构）折叠而成具有特定三维构象（二 / 三 / 四级结构）的功能分子。**蛋白质设计**旨在“逆向工程”这一过程——即从功能需求出发，设计出能实现该功能的氨基酸序列与结构。

传统蛋白设计方法（如 Rosetta）依赖物理能量函数与大量专家经验，需筛查数万甚至数十万候选分子才能找到一个可行设计，周期长、成本高、泛化能力有限。

1.2 AI 的革命性突破

2020 年, DeepMind 发布 [AlphaFold2](#), 将蛋白质结构预测精度从竞赛冠军水平大幅提升, 将预测时间从数月压缩至数小时。这一里程碑奠定了深度学习在蛋白质科学中的核心地位, 并于 2024 年获得诺贝尔化学奖。

此后, 基于预训练大模型的**蛋白质语言模型 (PLM)**、**扩散生成模型**、**多模态基础模型**相继涌现, 形成覆盖"结构预测 → 序列设计 → 功能注释"全链路的 AI 工具生态。

1.3 市场与应用背景

据 [DataM Intelligence \(2026\)](#) 的行业分析, AI 蛋白设计市场竞争持续升温, 主要参与者包括 DeepMind、Generate:Biomedicines、Insilico Medicine、Cradle、Profluent 等。行业估计 AI 赋能工具可将早期研发周期缩短 40–60%, 药物发现与先导优化占最大应用份额 (约 33.7%)。

主流基础模型与工具全景

2.1 结构预测类模型

AlphaFold3 (Google DeepMind & Isomorphic Labs, 2024)

AlphaFold3 是 AlphaFold 系列的第三代, 于 2024 年 5 月发表于 [Nature](#), 同年 11 月开放学术源代码。其核心创新在于将预测范围从蛋白质单体扩展至**所有生命分子**——蛋白质、DNA、RNA、小分子配体 (药物)、翻译后修饰及离子的联合三维结构均可预测。

技术架构上, AlphaFold3 保留了改进的 Evoformer 模块, 并引入**扩散网络** (类似于图像生成中的 DALL-E / Stable Diffusion) 进行最终原子坐标的生成。在 PoseBusters 基准测试中, AlphaFold3 对蛋白质 - 配体互作的预测精度比最佳传统方法高出 **50%**, 是首个在生物分子结构预测上超越物理方法的 AI 系统。[AlphaFold Server](#) 提供免费在线访问, AlphaFold 蛋白结构数据库已覆盖逾 **2.14** 亿个蛋白质结构。

Chai-1 (Chai Discovery, 2024)

[Chai-1](#) 是一个完全开源的多模态生物分子结构预测基础模型, 权重和推理代码以 Python 包形式发布, 非商业免费使用, 商业药物发现场景亦可通过网络界面免费访问。

Chai-1 在蛋白质 - 配体预测 (PoseBusters 基准成功率 **77%**, 与 AlphaFold3 的 76% 相当)、蛋白质多聚体预测 (DockQ 成功率 **0.751** vs. AF-Multimer2.3 的 **0.677**) 以及抗体 - 抗原复合体预测上均达到或超越当时最优水平。此外, Chai-1 支持**实验约束提示** (如交叉连接质谱、表位图谱数据), 可显著提升困难靶点的预测精度。

Boltz-1 (MIT CSAIL & Jameel Clinic, 2024)

Boltz-1 是 MIT 开发的完全开源生物分子互作建模系统，预测能力与 AlphaFold3 相当，是目前学术界最具可访问性的高精度多分子结构预测工具之一。**ABCFold** 工具进一步提供了 AlphaFold3、Boltz-1、Chai-1 的标准化统一接口，便于横向比较。

2.2 生成式骨架设计模型

RFdiffusion (Baker Lab, 华盛顿大学, 2023)

RFdiffusion 基于 RoseTTAFold 结构预测网络，通过扩散模型对蛋白质骨架生成任务进行微调，发表于 *Nature*。它在从头单体设计、拓扑约束蛋白设计、**蛋白质结合剂设计**、对称寡聚体设计、酶活性位点脚手架及对称 Motif 脚手架等多类任务上全面超越既有方法，并经数百个 AI 生成蛋白质的实验验证。单个计算成功设计的实验成功率相比传统方法提升了 **1-2 个数量级**。

RFdiffusion2 (Baker Lab + MIT, 2025)

RFdiffusion2 (2025 年 4 月发布) 在原版基础上引入**流匹配训练** (Flow Matching)、旋转异构体推断及残基索引推断能力，专注于**酶活性位点设计**。RFdiffusion2 仅需输入化学反应描述，即可生成带有定制活性位点的完整蛋白质骨架，无需专家预设原子级细节。

在包含 41 个挑战性酶设计问题的 AME 基准测试中，RFdiffusion2 解决了**全部 41 个**案例，而此前最优方法仅解决 16 个。实验室测试表明，每个案例测试不足 100 个设计即可获得活性酶，锌水解酶设计活性比此前方法高出数个数量级。

FrameDiff / SE(3) Diffusion (MIT CSAIL, 2023)

FrameDiff 是 RFdiffusion 的简化替代方案，基于 SE(3) 刚体不变扩散框架，无需依赖预训练结构预测网络，可独立生成最长约 500 个氨基酸的新颖蛋白质骨架，并与 RoseTTAFold2 结合演化为 RFdiffusion。

2.3 序列设计模型

ProteinMPNN (Baker Lab, 2022)

ProteinMPNN 是当前最广泛使用的固定骨架序列设计模型，基于消息传递神经网络 (MPNN) 图神经网络架构，输入蛋白质骨架坐标 (PDB 格式)，输出氨基酸序列。每条序列生成约需 **1-2 秒** (GPU)，在天然蛋白单体上的序列回收率约 **50-55%**。ProteinMPNN 支持单链、多链、对称约束等多种设计场景，是 RFdiffusion 骨架生成后标准的序列设计工具。

LigandMPNN (Baker Lab, 2025)

LigandMPNN (2025 年 3 月发布，成果发表于 *Nature Methods*) 是 ProteinMPNN 的扩展版本，显式建模非蛋白原子 (小分子、核苷酸、金属离子) 的空间与化学上下文。在蛋白质 - 小分子 (序列回收率 **63.3% vs. ProteinMPNN 的 50.5%**)、蛋白质 - 核酸 (50.5% vs. 34.0%) 和蛋白质 - 金属 (77.5% vs. 40.6%) 场景下均大幅优于 ProteinMPNN 和 Rosetta。已用于设计逾 **100 个**经实验验证的小分子和 DNA 结合蛋白。

2.4 蛋白质语言模型 (PLM)

ESM3 (EvolutionaryScale, 2024–2025)

ESM3 是 EvolutionaryScale 发布的前沿多模态生成式语言模型，旗舰版本参数量达 **980 亿**，在超过 **10^{24} FLOPS** 的算力下训练，发表于 *Science* (2025 年 1 月)。ESM3 同时对蛋白质**序列、结构和功能**三个模态进行推理，使用离散化词表将三维结构和功能关键词编码为标记序列，以掩码语言建模 (MLM) 目标训练。

ESM3 能生成与已知蛋白质序列相似度低于 **20%**、TM-score 约 **0.52** 的新型折叠结构，并通过类 RLHF 的自我对齐进一步提升生成质量。其突破性案例 **esmGFP** 与自然界最近荧光蛋白序列相似度仅 **58%** (58% 序列相同 = 42% 突变)，相当于“模拟 5 亿年进化”。开源版 ESM3 1.4B 权重可免费获取。

ESM2 + ESMFold (Meta AI, 2022–2023)

ESMFold 是基于 ESM2 蛋白质语言模型的端到端结构预测工具，以语言模型嵌入替代多序列比对 (MSA) 检索，速度比 AlphaFold2 快约 **60 倍**，适合大规模快速筛查。ESM2 (规模从 8M 到 15B 参数) 在蛋白质进化尺度数据上训练，其嵌入被广泛用于下游结构预测、功能预测和序列设计管线中。

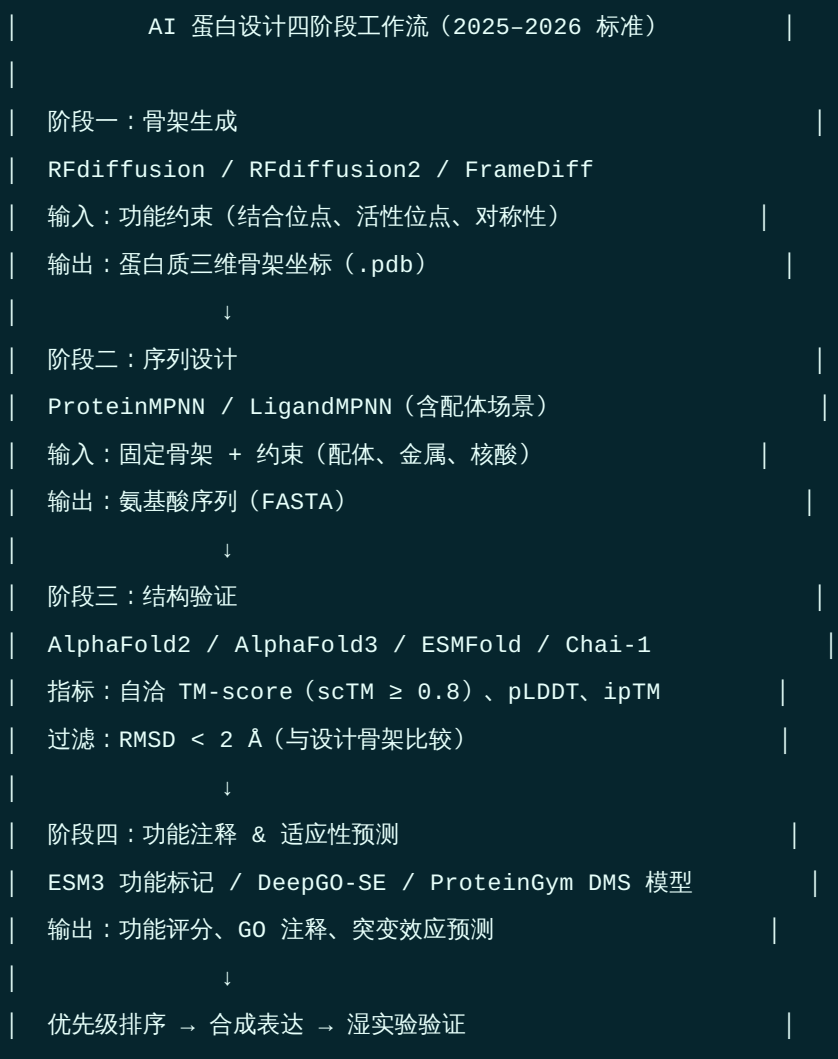
2.5 功能预测工具

DeepGO-SE 基于 ESM2 嵌入结合神经符号推理，将蛋白质功能预测形式化为语义蕴含问题，在基因本体 (GO) 功能注释上取得显著提升，发表于 *Nature Machine Intelligence* (2024)。

ProteinGym 是蛋白质适应性 (fitness) 预测领域最权威的大规模基准集，提供 2000 余个深度突变扫描 (DMS) 数据集，用于比较不同模型在突变效应预测任务上的性能，发表于 *NeurIPS 2023*。

序列 - 结构 - 功能标准工作流

当前 AI 蛋白设计领域已形成较为成熟的**四阶段计算工作流**，如下所示：



3.1 阶段一：骨架生成

在给定设计目标（结合特定靶蛋白的 binder、具备特定活性位点的酶、对称纳米粒子等）后，使用 RFdiffusion 或 RFdiffusion2 从噪声中迭代去噪生成满足约束的蛋白质骨架。典型参数：长度 50–400 个氨基酸，单次生成数十至数千条骨架。

3.2 阶段二：序列设计

使用 ProteinMPNN 对每条骨架在约束下生成多条候选氨基酸序列（每条骨架通常生成 8–32 条序列）。若设计目标涉及小分子、核酸或金属离子的结合，应改用 LigandMPNN 以显式建模非蛋白原子上上下文，可将序列回收率提升 **10–40%**。

3.3 阶段三：结构验证（自洽过滤）

将设计序列输入独立的结构预测模型（AlphaFold2 / AlphaFold3 / ESMFold），若预测结构与设计骨架的 **scTM-score ≥ 0.8** （或 **RMSD $< 2 \text{ \AA}$** ）则视为高质量设计。这一步是核心过滤环节：传统方法中，通过率往往不足 1%；使用 RFdiffusion + ProteinMPNN 组合后，通过率可提升至 **10–50%**，大幅减少实验验证工作量。

3.4 阶段四：功能注释与适应性预测

通过 ESM3 的功能标记提示、DeepGO-SE 的 GO 术语预测，以及 ProteinGym 上预训练的零样本适应性预测模型，对候选设计进行功能筛选和突变效应预估，进一步缩减需要湿实验验证的候选集合。

模型对比表

模型	类别	主要功能	输入	输出	开源情况	关键性能指标
AlphaFold3	结构预测	蛋白质 / DNA / RNA / 小分子 / 离子联合结构预测	序列 + SMILES	三维原子坐标	学术免费（权重）	PoseBusters 成功率 76%，比传统方法高 50%
Chai-1	结构预测	多模态生物分子结构预测 + 实验约束提示	序列 / SMILES / 实验约束	三维坐标 + 置信度	完全开源	PoseBusters 77%；蛋白质多聚体 DockQ 0.751（优于 AF-Multimer）
Boltz-1	结构预测	生物分子互作建模	序列 + SMILES	三维结构	完全开源	性能与 AlphaFold3 相当
ESMFold	结构预测	单序列快速结构预测（无需 MSA）	单条氨基酸序列	三维坐标 + pLDDT	完全开源	速度比 AlphaFold2 快 ~60 倍；适合大规模筛查
RFdiffusion	骨架生成	从头蛋白质骨架设计（binder / 酶 / 对称体）	功能约束 / 靶蛋白结构	骨架坐标 (.pdb)	完全开源	皮摩尔级结合剂；实验成功率提升 10–100 倍
RFdiffusion2	骨架生成（酶）	酶活性位点脚手架设计	化学反应描述 / Theozyme	带活性位点骨架	开源（学术）	AME 基准全 41/41；前最优方法仅 16/41
ProteinMPNN	序列设计	固定骨架序列设计（单链 / 多链 / 对称）	骨架坐标 (.pdb)	氨基酸序列 (FASTA)	完全开源	序列回收率 ~50–55%；1–2 秒 / 条（GPU）
LigandMPNN	序列设计	含配体 / 核酸 / 金属的蛋白质序列设计	骨架 + 非蛋白原子	氨基酸序列 + 侧链构象	完全开源	小分子场景序列回收率 63.3%（ProteinMPNN 50.5%）
ESM3	多模态 PLM	序列 / 结构 / 功能联合推理与生成	序列 / 结构 / 功能标记（任意组合）	序列 / 结构 / 功能预测	1.4B 开源；98B 商用	esmGFP：与最近自然荧光蛋白序列相似度仅 58%；pTM>0.8
ESM2	蛋白质语言模型	序列嵌入（下游任务通用骨干）	氨基酸序列	残基嵌入向量	完全开源（8M–15B）	进化尺度预训练；广泛用于下游结构 / 功能任务
DeepGO-SE	功能预测	GO 本体功能注释（神经符号推理）	氨基酸序列	GO 功能标签	开源	蛋白质 - 蛋白质互作预测 AUROC 提升 0.12
ProteinGym	基准评估	蛋白质适应性预测基准	序列 + 突变	适应性得分	完全开源	2000+ DMS 数据集；零样本适应性预测黄金标准

实施建议

4.1 项目启动阶段：选型建议

针对不同设计目标的推荐工具组合：

设计场景	推荐骨架生成	推荐序列设计	推荐结构验证	备注
蛋白质结合剂（binder）设计	RFdiffusion	ProteinMPNN	AlphaFold2 / Chai-1	成熟工作流，已有大量实验验证
含小分子酶 / 传感器设计	RFdiffusion2	LigandMPNN	AlphaFold3	明确配体时优先选用
新型酶活性位点设计	RFdiffusion2	LigandMPNN	AlphaFold3	仅需描述化学反应
大规模文库快速筛查	ESM3 功能提示	ESM3 / ProteinMPNN	ESMFold	速度优先；pLDDT 作为初筛
多分子复合体 / 抗体设计	—	ProteinMPNN	Chai-1 / AlphaFold3	Chai-1 在抗体 - 抗原预测上表现突出
蛋白质适应性工程	—	—	ESM2 嵌入 + ProteinGym 模型	突变效应零样本预测

4.2 计算基础设施建议

- **小规模探索** (< 100 设计) : Google Colab + Chai Discovery Lab Server + [AlphaFold Server](#) 可满足需求, 零本地 GPU 配置。
- **中规模设计活动** (100–10,000 设计) : 推荐至少 4 × NVIDIA A100 80GB 节点, 或使用云端 GPU (AWS / GCP / Azure) 。
- **大规模工业级流水线**: 建议在 HPC 集群上部署, 结合 SLURM 作业调度与 Nextflow / Snakemake 工作流管理系统。

4.3 工作流集成建议

1. **使用 [OpenProtein.AI](#) 等平台**: 对于没有深度计算背景的生物学家, OpenProtein.AI 提供无代码界面、PoET-2 蛋白质语言模型及 API 接口, 已被勃林格殷格翰等大型药企采用。
2. **建立"计算 → 实验"迭代循环**: 以计算过滤后的候选库 (通常 30–200 个序列) 作为第一轮实验验证批次, 用实验数据反馈更新模型或筛选策略。
3. **多模型集成验证**: 结构验证步骤建议同时使用至少两种独立预测模型 (如 AlphaFold3 + ESMFold), 以降低单一模型幻觉导致的误选风险。
4. **版本控制和复现性**: 使用 Docker 容器或 Conda 环境锁定模型版本; 所有设计参数和随机种子需记录, 确保计算可重现。

风险与局限性

5.1 模型幻觉与过度自信

AI 蛋白设计模型本质上是**生成式概率模型**, 其输出在计算层面可能看似合理 (高 pLDDT、高 scTM), 但实际湿实验中可能无法折叠或不具备目标功能。模型置信度评分与真实实验成功率之间存在显著差距, 应避免将高 pLDDT 直接等同于实验成功。

5.2 复杂靶点能力不足

正如行业观察者指出 ([LinkedIn, 2026](#)), 当前从头设计方法在结构数据稀缺的靶点上效果有限, 包括:

- **离子通道** (跨膜拓扑复杂)
- **复杂 GPCR 类** (构象柔性大、表达困难)
- **多结构域大型蛋白** (长程相互作用难以建模)

5.3 训练数据偏差

所有现有模型均在公开蛋白质数据库（PDB、UniRef、UniProt）上训练，对进化上稀少或实验结构缺乏的蛋白质家族泛化能力有限。此外，可溶性单结构域蛋白训练数据远多于膜蛋白和大型复合体，导致模型在后者上表现较差。

5.4 开源与商业授权问题

- **AlphaFold3**: 权重开放，但明确禁止商业使用；学术研究受少量限制。
- **Chai-1**: 非商业免费，商业药物发现通过网络界面免费访问，但大规模商业部署需确认许可。
- **ESM3 (98B)**: 商业版本通过 EvolutionaryScale API 访问，开源版本为 1.4B 参数。
- **RFdiffusion / ProteinMPNN / LigandMPNN**: 完全开源（MIT 许可），商业可用。

5.5 计算成本

大型模型（AlphaFold3、ESM3 98B）的单次推理成本较高，大规模工业流水线的计算成本不可忽视。ESMFold 或 Chai-1 单序列模式可作为初筛高效替代方案，在精度与速度之间取得平衡。

5.6 实验验证仍是决定性环节

据 MIT News (2026)，尽管 AI 工具显著加速了候选库生成，实验验证（蛋白表达、纯化、功能测定、结构表征）仍是决定设计成败的最终环节，且通常是整个流程的时间和成本主要来源。

总结与展望

2026 年，AI 蛋白设计领域已从“概念验证”阶段进入“工程应用”阶段：

- **结构预测精度**已不再是核心瓶颈，重心转向生成式设计的质量、效率与可控性；
- **酶设计**（RFdiffusion2）和**配体结合蛋白设计**（LigandMPNN）取得突破性进展，正向临床应用转化；
- **多模态基础模型**（ESM3）开创了序列 - 结构 - 功能统一推理的新范式；
- **平台化工具**（OpenProtein.AI、Chai Discovery Lab 等）正在降低领域准入门槛，推动生物学家直接使用 AI 工具；
- 未来 2-3 年内，全原子从头设计能力（包括动态蛋白、变构调控蛋白）预计将成为下一个突破方向。

核心建议：以 RFdiffusion + ProteinMPNN/LigandMPNN + AlphaFold3/Chai-1 作为标准起点 workflow，结合 ESM3 进行多模态功能引导，并始终维持与湿实验室的紧密迭代反馈循环。

参考文献

1. Abramson, J. et al. (2024). **Accurate structure prediction of biomolecular interactions with AlphaFold 3**. Nature, 630, 493–500. <https://www.nature.com/articles/s41586-024-07487-w>
2. Hayes, T. et al. (2025). **Simulating 500 million years of evolution with a language model**. Science, 371. <https://www.science.org/doi/10.1126/science.ads0018>
3. Watson, J.L. et al. (2023). **De novo design of protein structure and function with RFdiffusion**. Nature, 620, 1089–1100. <https://www.bakerlab.org/2023/07/11/diffusion-model-for-protein-design/>
4. Dauparas, J. et al. (2022). **Robust deep learning-based protein sequence design using ProteinMPNN**. Science, 378, 49–56. <https://www.science.org/doi/10.1126/science.add2187>
5. Dauparas, J. et al. (2025). **Atomic context-conditioned protein sequence design using LigandMPNN**. Nature Methods. <https://www.nature.com/articles/s41592-025-02626-1>
6. Institute for Protein Design (2025). **Introducing RFdiffusion2**. <https://www.ipd.uw.edu/2025/04/introducing-rfdiffusion2/>
7. Institute for Protein Design (2025). **Introducing LigandMPNN**. <https://www.ipd.uw.edu/2025/03/introducing-ligandmpnn/>
8. Chai Discovery Team (2024). **Chai-1: Decoding the molecular interactions of life**. bioRxiv. <https://github.com/chaidiscovery/chai-lab>
9. Wohlwend, J. et al. (2024). **Boltz-1: Democratizing Biomolecular Interaction Modeling**. bioRxiv. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11601547/>
10. Lin, Z. et al. (2023). **Evolutionary-scale prediction of atomic-level protein structure with a language model (ESMFold)**. Science, 379, 1123–1130. <https://www.science.org/doi/10.1126/science.ade2574>
11. EvolutionaryScale (2024). **ESM3: Simulating 500 million years of evolution with a language model** (blog post). <https://www.evolutionaryscale.ai/blog/esm3-release>
12. Kulmanov, M. & Hoehndorf, R. (2024). **Protein function prediction as approximate semantic entailment (DeepGO-SE)**. Nature Machine Intelligence. <https://www.nature.com/articles/s42256-024-00795-w>
13. Notin, P. et al. (2023). **ProteinGym: Large-Scale Benchmarks for Protein Fitness Prediction and Design**. NeurIPS 2023. https://papers.nips.cc/paper_files/paper/2023/hash/cac723e5ff29f65e3fcb0739ae91bee-Abstract-Datasets_and_Benchmarks.html

14. Yim, J. et al. (2023). **SE(3) diffusion model with application to protein backbone generation (FrameDiff)**. arXiv. <https://arxiv.org/abs/2302.02277>
 15. Elliott, L.G. et al. (2025). **ABCFold: easier running and comparison of AlphaFold 3, Boltz-1, and Chai-1**. Bioinformatics Advances, 5(1), vbaf153. <https://academic.oup.com/bioinformaticsadvances/article/5/1/vbaf153/8176613>
 16. MIT News (2026). **Bringing AI-driven protein-design tools to biologists everywhere (OpenProtein.AI)**. <https://news.mit.edu/2026/bringing-ai-driven-protein-design-tools-everywhere-0417>
 17. Isomorphic Labs / Google DeepMind (2024). **AlphaFold 3 predicts the structure and interactions of all of life's molecules**. <https://www.isomorphiclabs.com/articles/alphafold-3-predicts-the-structure-and-interactions-of-all-of-lifes-molecules>
 18. AlphaFold Protein Structure Database. <https://alphafold.ebi.ac.uk>
 19. DataM Intelligence (2026). **AI Protein Design Market Forecast and Industry Trends 2033**. <https://www.datamintelligence.com/research-report/ai-protein-design-market>
 20. Nature News (2024). **AI protein-prediction tool AlphaFold3 is now more open**. <https://www.nature.com/articles/d41586-024-03708-4>
-

本报告基于公开来源信息编写，不包含任何私有或机密数据。所有引用模型均为公开发布的学术研究成果或开源项目。